


第六章 知识学习决策

目录:

- 逻辑Agent
- 决策
- 学习

2

逻辑Agent



逻辑Agent



逻辑Agent

- 我们如何将问题描述为智能Agent能理解的形式?
- 或者说, 如何描述知识?
- 回答这个问题, 首先要定义什么是知识。
- 由于自然界中并没有知识, 所以某种程度上, 知识的定义就是知识本身。
- 启发式中, 我们将知识描述为启发函数, 这种方式很精巧, 但需要对知识有极高的抽象, 现实中使用场景往往较小。


逻辑Agent

- 世界是变化的
- 世界的变化符合自然规律, 但在细节上穷尽复杂
- 世界几乎不可能完全观察的
- 因为这个特点, 世界的变化既有客观的, 也有随机的。
- 我们称立足世界的客观变化的Agent为逻辑Agent。




逻辑Agent


- 知识是对事物变化规律的认识




- 最常见的形式是通过长期的观察和学习总结的经验
- 所以这里涉及的问题是：知识如何产生、记录和传递



逻辑Agent




逻辑Agent




苹果 → 可以吃
 苹果 + 大树 → 不可以吃
 苹果 + 大树 + 木棍 → 可以吃


逻辑Agent



逻辑Agent




逻辑Agent



逻辑Agent

- 在计算机科学和人工智能领域，本体论语言是指用于构建本体的形式语言。
- 常见本体语言：
 - RDF (Resource Description Framework, 基于XML)
 - OWL (Web Ontology Language, 基于RDF)
 - KM (Knowledge Machine, 基于LISP)
- 其它还有F-Logic、OKBC、OIL等

逻辑Agent



大树(苹果), 木棍 → 吃

使用规则表述为:

[rule: (大树 owl:hasValue ?A), (木棍) → (?A可以吃)]

Agent如何自己做到这一切?

逻辑Agent


- 世界是变化的，Agent在变化的世界中，既需要考虑世界的描述，也需要考虑世界的变化。
- 对世界基于客观规律的变化的推演，称为逻辑推理。
- 雨滴从天上落下。
- 河流流到海里。
- 对不确定性未来的评估，称为概率预测。
- 我出门会不会被狗咬?
- 今天是否能像昨天一样捡到钱?

逻辑Agent

- Agent要做到：
 - 描述世界的状态
 - 更新世界的状态
 - 抽象和理解感知到的信号
 - 演绎世界的状态
 - 演绎自己动作对世界状态的影响
- ```
function KB-Agent(percept) returns an action
static: KB, a knowledge base
 t, a counter, initially 0, indicating time
Tell(KB, Make-Percept-Sentence(percept, t))
action ← Ask(KB, Make-Action-Query(t))
Tell(KB, Make-Action-Sentence(action, t))
t ← t + 1
return action
```


## 逻辑Agent

- 评价
  - 黄金+1000
  - 死亡-1000
  - 每步-1
  - 使用弓箭-10
- 环境
  - 靠近wumpus的地方发臭
  - 靠近pit的地方有微风
  - 金子在的方块会闪光
- 执行器
  - 移动一格
  - 发射一支箭
  - 拾起黄金
- 感受器
  - 臭气
  - 微风
  - 闪光




## 逻辑Agent


- 可观察性或不可观察?
- 局部可观察
- 单或多Agent?
- 单
- 确定性或不确定?
- 环境是确定的
- 片段或延续?
- 片段的，因为操作级别上没有顺序
- 静态或动态?
- 静态的
- 离散或连续?
- 离散的




### 逻辑Agent




### 逻辑Agent




### 逻辑Agent




### 逻辑Agent




### 逻辑Agent




### 逻辑Agent



## 逻辑Agent



## 逻辑Agent



## 逻辑Agent

- 红色的两个方块都有微风时，Agent发现没有哪一步是安全的，此时怎么办？
- 可以对未知的状况进行估计
- 在这个问题中，Agent对pit的分布一无所知，因此可以假设它们是均匀分布的
- 思考：此时Agent应该如何选择？
- 这个问题的另一个变化是：
- 如果在红色的初始格子Agent就闻到臭味，是否要移动？




## 目录：

- 逻辑Agent：命题逻辑
- 决策
- 学习

26

## 命题逻辑

- 人脑对知识的加工与处理与记忆息息相关。记忆就是对信息的保存和再现能力。



## 命题逻辑

- 命题逻辑(proposition logic)是应用一套形式化规则对以符号表示的描述性陈述进行推理的系统。
- 在命题逻辑中，一个或真或假的描述性陈述被称为原子命题，对原子命题的内部结构不做任何解析。
- 若干原子命题可通过逻辑运算符来构成复合命题。

命题逻辑

下面给出了五个原子命题

p: 北京是中国的首都

q: 13能被6整除

r:  $x < 8$

s: 存在最大的素数

t:  $m^2 \geq 0$

- 命题p和命题t是真命题，命题q和命题s是假命题。命题r的真假依赖于x的取值，因此无法判断命题r的真假。

任何一个命题或为真、或为假或在给定条件下无法判断（需要进一步的条件约束）

命题逻辑

- 可通过命题联结词(connectives)对已有命题进行组合，得到新命题。这些通过命题联结词得到的命题被称为复合命题(compound proposition)。假设存在命题p和q，下面介绍五种主要的命题联结词：

| 命题连接符号               | 表示形式                  | 意义                                   |
|----------------------|-----------------------|--------------------------------------|
| 与(and)               | $p \wedge q$          | 命题合取(conjunction), 即 “p 且 q”         |
| 或(or)                | $p \vee q$            | 命题析取(disjunction), 即 “p 或 q”         |
| 非(not)               | $\neg p$              | 命题否定(negation), 即 “非p”               |
| 条件(conditional)      | $p \rightarrow q$     | 命题蕴含(implication), 即 “如果 p 则 q”      |
| 双向条件(bi-conditional) | $p \leftrightarrow q$ | 命题双向蕴含(bi-implication), 即 “p 当且仅当 q” |

命题逻辑

- 通过真值表来计算复合命题的真假。


| p     | q     | $\neg p$ | $p \wedge q$ | $p \vee q$ | $p \Rightarrow q$ | $p \Leftrightarrow q$ |
|-------|-------|----------|--------------|------------|-------------------|-----------------------|
| False | False | True     | False        | False      | True              | True                  |
| False | True  | True     | False        | True       | True              | False                 |
| True  | False | False    | False        | True       | False             | False                 |
| True  | True  | False    | True         | True       | True              | True                  |

命题逻辑

“条件”命题联结词中前提为假时命题真假取值

“如果p那么q( $p \rightarrow q$ )”定义的是一种蕴涵关系（即充分条件），也就是命题q包含着命题p（p是q的子集）

p不成立相当于p是一个空集，空集可被其他所有集合所包含，因此当p不成立时，“如果p那么q”永远为真。



命题逻辑

**逻辑等价：**给定命题p和命题q，如果p和q在所有情况下都具有同样真假结果，那么p和q在逻辑上等价，一般用 $\equiv$ 来表示，即  $p \equiv q$ 。



逻辑等价命题进行形式转换带来了可能，基于这些转换不再需要逐一列出p和q的真值表来判断两者是否在逻辑上等价，而是可直接根据已有逻辑等价公式来判断p和q在逻辑上是否等价。

命题逻辑

逻辑等价的例子

|                                                                                                   |                                                                                                                          |
|---------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| $\alpha \wedge \beta \equiv \beta \wedge \alpha$ ( $\wedge$ 的交互律)                                 | $(\alpha \Rightarrow \beta) \equiv \neg \alpha \vee \beta$ (蕴涵消除)                                                        |
| $\alpha \vee \beta \equiv \beta \vee \alpha$ ( $\vee$ 的交互律)                                       | $(\alpha \Leftrightarrow \beta) \equiv (\alpha \Rightarrow \beta) \wedge (\beta \Rightarrow \alpha)$ (双向消除)              |
| $(\alpha \wedge \beta) \wedge \gamma \equiv \alpha \wedge (\beta \wedge \gamma)$ ( $\wedge$ 的结合律) | $\neg(\alpha \wedge \beta) \equiv (\neg \alpha \vee \neg \beta)$ (De Morgan)                                             |
| $(\alpha \vee \beta) \vee \gamma \equiv \alpha \vee (\beta \vee \gamma)$ ( $\vee$ 的结合律)           | $\neg(\alpha \vee \beta) \equiv (\neg \alpha \wedge \neg \beta)$ (De Morgan)                                             |
| $\neg(\neg \alpha) \equiv \alpha$ (双重否定)                                                          | $(\alpha \wedge (\beta \vee \gamma)) \equiv (\alpha \wedge \beta) \vee (\alpha \wedge \gamma)$ ( $\wedge$ 对 $\vee$ 的分配律) |
| $(\alpha \Rightarrow \beta) \equiv \neg \beta \Rightarrow \neg \alpha$ (逆否命题)                     | $(\alpha \vee (\beta \wedge \gamma)) \equiv (\alpha \vee \beta) \wedge (\alpha \vee \gamma)$ ( $\vee$ 对 $\wedge$ 的分配律)   |

命题逻辑

|                                                                               |                                                                                                                                            |
|-------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| $(\alpha \Rightarrow \beta) \equiv \neg\beta \Rightarrow \neg\alpha$ (逆否命题)   | 秋天天气变凉 $\Rightarrow$ 大雁南飞越冬 $\equiv$ 大雁没有南飞越冬 $\Rightarrow$ 秋天天气没有变凉<br>$x \geq 0 \Rightarrow x^2 \geq 0 \equiv x^2 < 0 \Rightarrow x < 0$ |
| $(\alpha \Rightarrow \beta) \equiv \neg\alpha \vee \beta$ (蕴涵消除)              | $\alpha$ 为假, 则命题恒为真; $\alpha$ 为真, 则 $\beta$ 须为真                                                                                            |
| $\neg(\alpha \wedge \beta) \equiv (\neg\alpha \vee \neg\beta)$<br>(De Morgan) |                                                           |
| $\neg(\alpha \vee \beta) \equiv (\neg\alpha \wedge \neg\beta)$<br>(De Morgan) |                                                           |

命题逻辑

|                           |                                                                                                     |
|---------------------------|-----------------------------------------------------------------------------------------------------|
| 假言推理<br>(Modus Ponens)    | $\frac{\alpha \Rightarrow \beta, \alpha}{\beta}$                                                    |
| 与消解<br>(And-Elimination)  | $\frac{\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n}{\alpha_i (1 \leq i \leq n)}$          |
| 与导入<br>(And-Introduction) | $\frac{\alpha_1, \alpha_2, \dots, \alpha_n}{\alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_n}$ |

命题逻辑

|                                          |                                                                                                                                                                                                                                                                     |
|------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 双重否定<br>(Double-Negation<br>Elimination) | $\frac{\neg\neg\alpha}{\alpha}$                                                                                                                                                                                                                                     |
| 单项消解或单项归结<br>(Unit Resolution)           | $\frac{\alpha \vee \beta, \neg\beta}{\alpha}$                                                                                                                                                                                                                       |
| 消解或归结<br>(Resolution)                    | $\frac{\alpha \vee \beta, \neg\beta \vee \gamma}{\alpha \vee \gamma}, \frac{\alpha_1 \vee \alpha_2 \vee \dots \vee \alpha_m, \neg\beta}{\alpha_1 \vee \alpha_2 \vee \dots \vee \alpha_{k-1} \vee \alpha_{k+1} \vee \dots \vee \alpha_m} (\neg\alpha_k = \neg\beta)$ |

命题逻辑

|   |                          |                       |
|---|--------------------------|-----------------------|
| 1 | $\alpha \vee \beta$      | 已知                    |
| 2 | $\neg\alpha \vee \gamma$ | 2进行蕴涵消除               |
| 3 | $\neg\beta \vee \gamma$  | 3进行蕴涵消除               |
| 4 | $\neg\gamma$             | 假设命题 $\gamma$ 不成立     |
| 5 | $\beta \vee \gamma$      | 1和2进行归结               |
| 6 | $\neg\alpha$             | 2和4进行归结               |
| 7 | $\neg\beta$              | 3和4进行归结               |
| 8 | $\gamma$                 | 5和7进行归结               |
| 9 |                          | 假设不成立, 命题 $\gamma$ 成立 |

1

$\alpha \vee \beta$

2

$\alpha \Rightarrow \gamma$

3

$\beta \Rightarrow \gamma$

已知如上命题成立,  
请证明命题 $\gamma$ 是成立的

命题逻辑

|   |                             |         |
|---|-----------------------------|---------|
| 1 | $\alpha \vee \beta$         | 已知      |
| 2 | $\neg\alpha \vee \beta$     | 已知      |
| 3 | $\alpha \vee \neg\beta$     | 已知      |
| 4 | $\neg\alpha \vee \neg\beta$ | 已知      |
| 5 | $\beta$                     | 1和2进行归结 |
| 6 | $\neg\beta$                 | 3和4进行归结 |

证明如上命题集是不可满足的

因此, 从该命题集中同时推出命题 $\beta$ 和命题 $\neg\beta$ , 因此原命题集是不可满足的

命题逻辑

|   |                              |         |
|---|------------------------------|---------|
| 1 | $\alpha \vee \gamma$         | 已知      |
| 2 | $\neg\beta \vee \gamma$      | 已知      |
| 3 | $\neg\gamma \vee \alpha$     | 已知      |
| 4 | $\neg\alpha \vee \beta$      | 已知      |
| 5 | $\neg\alpha \vee \neg\gamma$ | 已知      |
| 6 | $\alpha$                     | 1和3进行归结 |
| 7 | $\beta$                      | 4和6进行归结 |
| 8 | $\gamma$                     | 2和7进行归结 |
| 9 | $\neg\alpha$                 | 5和8进行归结 |

证明如上命题集是不可满足的

从该命题集中可同时推出 $\alpha$ 和 $\neg\alpha$ 两个命题, 因此原命题集是不可满足的

## 命题逻辑

- 有限个简单合取式构成的析取式称为**析取范式**
- 由有限个简单析取式构成的合取式称为**合取范式**
- 析取范式与合取范式统称为**范式 (normal form)**

◆ 假设  $\alpha_i (i = 1, 2, \dots, k)$  为简单的合取式, 则  $\alpha = \alpha_1 \vee \alpha_2 \vee \dots \vee \alpha_k$  为析取范式  
例如:  $(\neg \alpha_1 \wedge \alpha_2) \vee \alpha_3, \neg \alpha_1 \vee \alpha_3 \vee \alpha_2$  等

◆ 假设  $\alpha_i (i = 1, 2, \dots, k)$  为简单的析取式, 则  $\alpha = \alpha_1 \wedge \alpha_2 \wedge \dots \wedge \alpha_k$  为合取范式  
例如:  $(\alpha_1 \vee \alpha_2) \wedge \neg \alpha_3, \neg \alpha_1 \wedge \alpha_3 \wedge (\neg \alpha_2 \vee \alpha_4)$  等

## 命题逻辑

- 一个析取范式是不成立的, 当且仅当它的每个简单合取式都不成立。
- 一个合取范式是成立的, 当且仅当它的每个简单析取式都是成立的。

- ◆ 任一命题公式都存在与之等值的析取范式与合取范式(注意: 命题公式的析取范式与合取范式都不是唯一的)

问题: 求  $\neg(\alpha \rightarrow \beta) \vee \neg\gamma$  的析取范式与合取范式

$$\begin{aligned} & \neg(\alpha \rightarrow \beta) \vee \neg\gamma \\ \Leftrightarrow & \neg(\neg\alpha \vee \beta) \vee \neg\gamma \\ \Leftrightarrow & (\alpha \wedge \neg\beta) \vee \neg\gamma \text{ (析取范式)} \\ \Leftrightarrow & (\alpha \vee \neg\gamma) \wedge (\neg\beta \vee \neg\gamma) \text{ (合取范式)} \end{aligned}$$

## 目录:

- 逻辑Agent: 谓词逻辑
- 决策
- 学习

51

## 谓词逻辑

- 命题逻辑的局限性: 在命题逻辑中, 每个陈述句是最基本的单位(即原子命题), 无法对原子命题进行分解。因此在命题逻辑中, 不能表达局部与整体、一般与个别的关系。
- 例如, 对于苏格拉底论断, 虽知其正确的, 但无法通过命题逻辑来进行推理判断:
  - $\alpha$ : 所有的人总是要死的
  - $\beta$ : 苏格拉底是人
  - $\gamma$ : 所以苏格拉底是要死的

$\alpha \wedge \beta \rightarrow \gamma$  (不是命题逻辑的有效推理)  
无法在命题逻辑基础上完成这样的推导

## 谓词逻辑

- $\alpha$ : 大象是哺乳动物
- $\beta$ : 大象是一种最大的哺乳动物

个体的性质 (是)、  
个体和个体之间的关系 (最大)

- 解决思路:
  - 不同原子命题蕴含个体、群体和关系等内在丰富语义, 命题逻辑无法表现内在丰富语义。因此, 需要分析原子命题, 分离其主语 (个体或群体) 和谓语 (关系)

需要引入更加强大的逻辑表示方法, 这就是谓词逻辑

## 谓词逻辑

- 在谓词逻辑中, 将原子命题进一步细化, 分解出个体、谓词和量词, 来表达个体与总体的内在联系和数量关系, 这就是谓词逻辑研究内容。
- 谓词逻辑中三个核心概念:
  - 个体、谓词 (predicate) 和量词 (quantifier)

## 谓词逻辑：谓词与个体

- $P(x)$  表示:  $x < x^2$
- $P$  是谓词,  $x$  是个体词,  $x$  被称为变量。  $x$  的具体取值叫个体常项。比如,  $P(0.1)$  和  $P(0.02)$  使得谓词为假。个体的取值范围为个体域。
- 一般用大写字母  $P, Q, R$  等来表示谓词。上述  $P(x)$  描述的是是否存在一个数, 这个数小于自身平方这种关系。
- 谓词中可以有若干个个体变量, 如  $\text{father}(x, y)$  表示  $x$  是  $y$  父亲。
- $P(x)$  是一元谓词 (包含一个个体),  $P(x_1, x_2, \dots, x_n)$  被称为  $n$  元谓词 (包含若干个个体)。

## 谓词逻辑：量词

- 全称量词(universal quantifier,  $\forall$ )
  - 全称量词用符号  $\forall$  表示, 表示一切的、凡是、所有的、每一个等。  
 $\forall x$  表示定义域中的所有个体,  $\forall x P(x)$  表示定义域中的所有个体具有性质  $P$
- 存在量词(existential quantifier,  $\exists$ )
  - 存在量词用符号  $\exists$  表示, 表示存在、有一个、某些等。  $\exists x$  表示定义域中存在一个或若干个个体,  $\exists x P(x)$  表示定义域中存在一个个体或若干个个体具有性质  $P$
- 全称量词和存在量词统称为量词。

## 谓词逻辑：量词

- 全称量词
  - 谓词  $P(x)$ :  $x$  能够制造工具。  $\forall x P(x)$  表示定义域中的所有个体能够制造工具。  $P(\text{小王})$  表示小王能够制造工具。
- 存在量词
  - 谓词  $P(x)$ :  $x$  能够制造工具。  $\exists x P(x)$  表示定义域中的存在某个/某些个体能够制造工具。  $P(\text{小王})$  表示小王能够制造工具 (该命题或者为真、或者为假)。

## 谓词逻辑：量词

- 全称量词与存在量词之间的组合
  - $\forall x \neg P(x) \equiv \neg \exists x P(x)$
  - $\neg \forall x P(x) \equiv \exists x \neg P(x)$
  - $\forall x P(x) \equiv \neg \exists x \neg P(x)$
  - $\exists x P(x) \equiv \neg \forall x \neg P(x)$

## 谓词逻辑：函数与谓词的区别

- 函数中个体变元用个体常量 (来自定义域) 代入后结果仍是个体 (值域), 如定义函数  $f(x) = x + 10$ , 则  $f(2) = 12$
- 谓词中个体变元用个体常量代入后就变成了命题, 如  $\text{car}(x)$  ( $x$  是车) 这个谓词中  $x$  用吉普车代替, 则  $\text{car}(\text{吉普车})$  是命题。
- 函数是从定义域到值域的映射; 谓词是从定义域到  $\{\text{True}, \text{False}\}$  的映射

## 谓词逻辑：谓词演算的合式公式

- 命题常项、命题变项、原子谓词 (不存在任何量词与联结词) 是合式公式。
- 如果  $A$  和  $B$  是合式公式, 那么  $\neg A$ 、 $A \wedge B$ 、 $A \vee B$ 、 $A \rightarrow B$ 、 $A \leftrightarrow B$  都是合式公式
- 如果  $A$  是合式公式,  $x$  是个体变元, 则  $\exists x A(x)$  和  $\forall x A(x)$  也是合式公式
- 有限次地使用上述规则求得公式是合式公式

## 谓词逻辑：若干谓词逻辑的推理规则

- 全称量词消去(Universal Instantiation, UI):  $(\forall x)A(x) \rightarrow A(y)$
- 全称量词引入(Universal Generalization, UG):  $A(y) \rightarrow (\forall x)A(x)$
- 存在量词消去(Existential Instantiation, EI):  $(\exists x)A(x) \rightarrow A(c)$
- 存在量词引入(Existential Generalization, EG):  $A(c) \rightarrow (\exists x)A(x)$

## 谓词逻辑

已知:

- $(\forall x)(P(x) \rightarrow Q(x))$
- $(\forall x)(Q(x) \rightarrow R(x))$

试证明:  $(\forall x)(P(x) \rightarrow R(x))$

证明过程:

- $(\forall x)(P(x) \rightarrow Q(x))$
- $P(x) \rightarrow Q(x)$  (消去全称量词)
- $(\forall x)(Q(x) \rightarrow R(x))$
- $Q(x) \rightarrow R(x)$  (消去全称量词)
- $P(x) \rightarrow R(x)$
- $(\forall x)(P(x) \rightarrow R(x))$  (引入 $x$ )

## 谓词逻辑

证明过程:

1.  $(\forall x)(F(x) \rightarrow (G(x) \wedge H(x)))$  (已知)
2.  $(\exists x)(F(x) \wedge P(x))$  (已知)
3.  $F(a) \wedge P(a)$  (2的EI)
4.  $F(a) \rightarrow (G(a) \wedge H(a))$  (1的UI)
5.  $F(a)$  (由3知)
6.  $G(a) \wedge H(a)$  (4和5的假言推理)
7.  $P(a)$  (由3知)
8.  $H(a)$  (由6知)
9.  $P(a) \wedge H(a)$  (7和8的合取)
10.  $(\exists x)(P(x) \wedge H(x))$  (9的EG)

已知:

- $(\forall x)(F(x) \rightarrow (G(x) \wedge H(x)))$
- $(\exists x)(F(x) \wedge P(x))$

试证明:  $(\exists x)(P(x) \wedge H(x))$

## 谓词逻辑：自然语言的形式化

每一个奇数均存在一个大于它的奇数:

- $\text{odd}(x)$ :  $x$ 是奇数
- $\text{Great}(x, y)$ :  $x$  大于  $y$
- $(\forall x)(\text{odd}(x) \rightarrow (\exists y)(\text{odd}(y) \wedge \text{Great}(y, x)))$

## 谓词逻辑：自然语言的形式化

前提: 1) 每架飞机或者停在地面或者飞在天空; 2) 并非每架飞机都飞在天空

结论: 有些飞机停在地面

形式化:  $\text{plane}(x)$ :  $x$ 是飞机;  $\text{in\_ground}(x)$ :  $x$ 停在地面;  $\text{on\_fly}(x)$ :  $x$ 飞在天空

已知:  $(\forall x)(\text{plane}(x) \rightarrow \text{in\_ground}(x) \vee \text{on\_fly}(x))$ ,  $(\neg \forall x)\text{plane}(x) \rightarrow \text{on\_fly}(x)$

请证明:  $(\exists x)(\text{plane}(x) \wedge \text{in\_ground}(x))$

证明:

1.  $(\neg \forall x)\text{plane}(x) \rightarrow \text{on\_fly}(x)$  (已知)
2.  $(\exists x \neg(\text{plane}(x) \rightarrow \text{on\_fly}(x)))$
3.  $(\exists x \neg(\neg \text{plane}(x) \vee \text{on\_fly}(x)))$
4.  $(\exists x (\text{plane}(x) \wedge \neg \text{on\_fly}(x)))$


## 谓词逻辑：自然语言的形式化

1.  $(\neg \forall x)\text{plane}(x) \rightarrow \text{on\_fly}(x)$
2.  $(\exists x \neg(\text{plane}(x) \rightarrow \text{on\_fly}(x)))$
3.  $(\exists x \neg(\neg \text{plane}(x) \vee \text{on\_fly}(x)))$
4.  $(\exists x (\text{plane}(x) \wedge \neg \text{on\_fly}(x)))$
5.  $\text{plane}(a) \wedge \neg \text{on\_fly}(a)$
6.  $\text{plane}(a)$
7.  $\neg \text{on\_fly}(a)$
8.  $(\forall x)(\text{plane}(x) \rightarrow \text{in\_ground}(x) \vee \text{on\_fly}(x))$
9.  $\text{plane}(a) \rightarrow \text{in\_ground}(a) \vee \text{on\_fly}(a)$
10.  $\text{in\_ground}(a) \vee \text{on\_fly}(a)$
11.  $\text{in\_ground}(a)$
12.  $\text{plane}(a) \wedge \text{in\_ground}(a)$
13.  $(\exists x)(\text{plane}(x) \wedge \text{in\_ground}(x))$

## 谓词逻辑：专家系统




## 谓词逻辑：专家系统




## 谓词逻辑：知识图谱

- 知识图谱可视为包含多种关系的图。在图中，每个节点是一个实体（如人名、地名、事件和活动等），任意两个节点之间的边表示这两个节点之间存在的关系。
- 一般而言，可将知识图谱中任意两个相连节点及其连接边表示成一个三元组（*triplet*），即（*left\_node*, *relation*, *right\_node*），例：（David, *Father*, Mike）。



## 谓词逻辑：知识图谱



## 谓词逻辑：知识图谱

### □ 概念之间层次化关系(ontology):

□ 如：工程 → 水利工程

□ 与 Wordnet 等早期本体知识构建不同，现有方法多在传统分类法 (Taxonomy) 中结合大众分类 (Folksonomy) 和机器学习来构建语义网络分类体系。

### □ 概念对应的例子或实体(instance/entity)

□ 如三峡大坝和葛洲坝等属于水利工程这一概念。

□ 一般通过分类识别等手段实现。

## 谓词逻辑：知识图谱

### □ 概念或实体的属性:

□ 属性是对概念或实体内涵的描述，如水利工程具有建设时间和规模等属性、三峡大坝具有发电功能等属性。

### □ 概念或实体之间的关系:

□ 如三峡大坝和葛洲坝之间具有“梯级调节”关系。

### □ 概念或实体的属性描述和关系表达一般通过三元组来表示:

□ (*entity*, *relation*, *entity*) 或 (*subject*, *predicate*, *object*)


### □ 学习概念或实体属性描述及其关联关系是丰富知识图谱的关键!

## 谓词逻辑：知识图谱

- **概念**：层次化组织
- **实体**：概念的示例化描述
- **属性**：对概念或实体的描述信息
- **关系**：概念或实体之间的关联
- **推理规则**：可产生语义网络中上述新的元素

在实际中，知识图谱一般可通过标注多关系图（*labeled multi-relational graph*）来表示。

## 谓词逻辑：知识图谱




一个简单的家庭关系知识图谱

知识图谱中存在连线的两个实体可表达为形如<left\_node, relation, right\_node>的三元组形式，这种三元组也可以表示为一阶逻辑(first order logic, FOL)的形式，从而为基于知识图谱的推理创造了条件。

例如从<奥巴马, 出生地, 夏威夷>和<夏威夷, 属于, 美国>两个三元组, 可推理得到<奥巴马, 国籍, 美国>。


## 谓词逻辑：知识图谱



一个简单的家庭关系知识图谱

- 可利用一阶谓词来表达刻画知识图谱中节点之间存在的关系，如图中形如<James, Couple, David>的关系可用一阶逻辑的形式来描述，即Couple(James, David)。
- Couple(x, y)是一阶谓词，Couple是图中实体之间具有的关系，x和y是谓词变量
- 从图中已有关系可推知David和Ann具有父女关系，但这一关系在图中初始图(无红线)中并不存在，是需要推理的目标。

## 谓词逻辑：知识图谱



一个简单的家庭关系知识图谱

- 问题：如何从知识图谱中推理得到

*father(David, Ann)*



$(\forall x)(\forall y)(\forall z)(Mother(x, y) \wedge Couple(x, z) \rightarrow Father(x, y))$

如果能够学习到这条规则，该有多好？  
(从具体例子中学习，这是归纳推理的范畴)

## 谓词逻辑：知识图谱推理：FOIL

### FOIL: First Order Inductive Learner

$(\forall x)(\forall y)(\forall z)(Mother(z, y) \wedge Couple(x, z) \rightarrow \text{Father}(x, y))$

前提约束谓词  
(学习得到)

目标谓词  
(已知)

推理思路：从一般到特殊，逐步给目标谓词添加前提约束谓词，直到所构成的推理规则不覆盖任何反例。

从一般到特殊：对目标谓词或前提约束谓词中的变量赋予具体值，如将 $(\forall x)(\forall y)(\forall z)(Mother(z, y) \wedge Couple(x, z) \rightarrow Father(x, y))$ 这一推理规则所包含的目标谓词Father(x, y)中x和y分别赋值为David和Ann，进而进行推理。

## 谓词逻辑：知识图谱推理：FOIL

$(\forall x)(\forall y)(\forall z)(Mother(z, y) \wedge Couple(x, z) \rightarrow Father(x, y))$

前提约束谓词  
(学习得到)

目标谓词  
(已知)

推理手段: positive examples + negative examples + background knowledge examples  $\Rightarrow$  hypothesis

|      |                                                                                         |      |                                                                                             |
|------|-----------------------------------------------------------------------------------------|------|---------------------------------------------------------------------------------------------|
| 背景知识 | Sibling(Ann, Mike)<br>Couple(David, James)<br>Mother(James, Ann)<br>Mother(James, Mike) | 目标谓词 | Father(David, Mike)<br>~Father(David, James)<br>~Father(James, Ann)<br>~Father(James, Mike) |
| 样例   |                                                                                         | 训练样例 |                                                                                             |
| 集合   |                                                                                         | 集合   |                                                                                             |


给定目标谓词，FOIL算法从实例（正例、反例、背景样例）出发，不断测试所得到推理规则是否还包含反例，一旦不包含负例，则学习结束，展示了“归纳学习”能力。

## 谓词逻辑：知识图谱推理：FOIL


FOIL (First Order Inductive Learner) 算法

| FOIL算法 |                                                                                       |
|--------|---------------------------------------------------------------------------------------|
| 输入:    | 目标谓词 $P$ , $P$ 的训练样例 (正例集合 $E^+$ 和反例集合 $E^-$ ), 其他背景知识                                |
| 输出:    | 推导得到目标谓词 $P$ 的推理规则                                                                    |
| 1      | 将目标谓词作为所学习推理规则的结论                                                                     |
| 2      | 将其他谓词逐一作为前提约束谓词加入推理规则, 计算所得到推理规则的FOIL信息增益值。选取最优前提约束谓词以生成新推理规则, 并将训练样例集合中与该推理规则不符的样例去掉 |
| 3      | 重复2过程, 直到所得到的推理规则不覆盖任意反例                                                              |

## 谓词逻辑：知识图谱推理：FOIL

$$(\forall x)(\forall y)(\forall z)(Mother(z, y) \wedge Couple(x, z) \rightarrow \text{Father}(x, y))$$


## 谓词逻辑：知识图谱



## 目录:

- 逻辑Agent
- 决策
- 学习

82

## 决策


**像人一样思考** “有头脑的机器” (Haugeland, 1985) “与人类思维相关的活动, 如决策、求解、学习等的自动化” (Bellman, 1978)

**合理地思考** “通过计算机模型研究智力” (Charniak & McDermott, 1985) “使感知、推理和行动成为可能的计算的研究” (Winston, 1992)


**像人一样行动** “创造能执行某些功能的机器, 这些功能如果是人来执行的话需要智能” (Kurzweil, 1990) “研究如何使计算机能做哪些目前人比计算机更擅长的事情” (Rich & Knight, 1991)

**合理地行动** “智能Agent的设计” (Poole, 1998) “应关心人类造物的智能行为” (Nilsson, 1998)

## 决策



## 决策



## 决策

令  $A_i$  = 距离发车的剩余时间

• 假如打车的话,  $A_i$  足够我从学校赶往火车站吗?

• 问题:

局部可观察性 (道路状况, 出租车数量)

传感器有噪声 (导航APP反映的真实路况有滞后性)

行为结果不确定性 (打不到车、车半路爆胎)

环境建模需要交通预测 (交通预测需要什么? 准吗?)

• 冒险:  $A_{i,0}$  可以让我到达东站

• 放弃: 信息不足以让我做决策, 不去了

• 谨慎: 如果道路始终通畅, APP显示准确, 同时一出门就打到车, 车况良好不会半路爆胎, 那么  $A_{i,0}$  是足够的

• 过于谨慎:  $A_{i,100}$  可以保证赶上上车, 但我要在东站睡一晚上

• 如何处理不确定性?

## 决策

• 对不确定性进行判断受到这两部分的影响:

- 条件不全: 缺乏相关事实支撑或初始条件等
- 判断不全: 没有列举出所有情况

• 主观概率:

• 根据人们的知识对概率做判断, 如:

$$P(A_{45} | \text{路上没有事故}) = 0.8$$

• 但主观概率没有考虑当下的信息变化, 事实概率应随着新的证据的出现而变化, 如:

$$P(A_{45} | \text{路上没有事故, 出门打上车}) = 0.9$$

• 类似逻辑表示中的  $KB|\alpha$

## 决策

• 假设根据我的经验, 有如下的判断:

$$P(A_{25} | \text{让我准时到达} | \dots) = 0.04$$

$$P(A_{45} | \text{让我准时到达} | \dots) = 0.70$$

$$P(A_{120} | \text{让我准时到达} | \dots) = 0.95$$

$$P(A_{1440} | \text{让我准时到达} | \dots) = 0.9999$$

• 我要做哪种选择?


• 基于我对错过火车的可接受程度 (偏好性) 做选择。

• 效用论 (utility theory) 用于对偏好性进行表示和推断

决策 = 效用 + 概率

$$\text{Decision} = \text{utility} + \text{probability}$$

## 决策



## 决策

• 决策: 在环境状态  $s$  下采取行动  $a$  得到的确定性的输出结果

现实中, 环境状态能够直接建模吗?

$s$  要通过观察  $e$  来描述

现实中, 结果确定吗?  
此时我们如何处理?

平均预期: 期望  
最优估计  
最坏估计

$$P(\text{RESULT}(a) = s' | a, e)$$

## 决策

- 定义效用函数 $U(s)$ 表示Agent的偏好，那么行为的期望：

$$EU(a|e) = \sum_{s'} P(RESULT(a) = s' | a, e) U(s')$$


- 那么，理性Agent即总能够选择让期望效用最大化的行为的Agent（最大期望效用）：

$$action = \max_a EU(a|e)$$

- 思考：这个模型完美吗？

## 决策

- 偏好：Agent面临不确定性的奖励所做的行为判断
- 奖励： $L = [p, A; (1-p), B]$



- 记录Agent的偏好>（念作succeed）：
- $A > B$  Agent偏好A超过B
- $A \sim B$  Agent偏好A和B之间的差异
- $A \succeq B$  Agent偏好A超过或与B相同

## 决策

- 有序性

$$(A > B) \vee (B > A) \vee (A \sim B)$$

- 传递性

$$(A > B) \wedge (B > C) \Rightarrow (A > C)$$

- 连续性

$$(A > B > C) \Rightarrow \exists p[p, A; 1-p, C] \sim B$$

- 可替换

$$A > B \Rightarrow [p, A; 1-p, C] \sim [p, B; 1-p, C]$$

- 单调性


$$A > B \Rightarrow (p \geq q \Leftrightarrow [p, A; 1-p, B] \succeq [q, A; 1-q, B])$$

- 可分解性

$$\begin{aligned} & [p, A; 1-p, [q, B; 1-q, C]] \\ & \sim [p, A; (1-p)q, B; (1-p)(1-q), C] \end{aligned}$$

## 决策

- 违反这些约束，会引入非理性
- 如考虑这个破坏传递性的偏好： $A > B > C > A$
- A、B、C是可以自由交换的商品。
- 假设一开始Agent有A，我们提出用C + 1元购买A，Agent愿意交易吗？
- 同理，有C的agent会花1元得到B吗，有B的Agent会花1元得到A吗？这意味着什么？



## 决策

### 期望效用最大化 (MEU)

- 定理：
- 给定满足约束条件的偏好，存在一个实值函数 $U(x)$ 使得：  
 $U(A) \geq U(B) \Leftrightarrow A \succeq B$
- 据此可以定义行为的期望效用：  
 $U([p1, S1; \dots; pn, Sn]) = \sum_i p_i U(S_i)$
- MEU原则：选择使预期效用最大化的行动
- 在MEU下，Agent可以是完全理性的

## 目录：

- 逻辑Agent
- 决策：贝叶斯网络
- 学习

## 贝叶斯网络：概率基础

### 随机变量

- 随机变量用来表征环境中的不确定性。一般用大写字母表示。
  - R = 会下雨吗？
  - T = 冷还是热？
  - D = 开车上班要花多久？
  - L = 格子世界中的奶酪在哪里？
- 随机变量有取值范围
  - $R \in \{\text{true}, \text{false}\}$  (通常记为  $\{+r, -r\}$ )
  - $T \in \{\text{hot}, \text{cold}\}$
  - $D \in [0, \infty)$
  - $L \in$  可能的位置, 例如  $\{(0, 0), (0, 1), \dots\}$

## 贝叶斯网络：概率基础

### 概率分布

- 随机变量的取值可以对应到一个概率分布。

$$P(T)$$

| T    | P   |
|------|-----|
| hot  | 0.5 |
| cold | 0.5 |

$$P(W)$$

| W      | P   |
|--------|-----|
| sun    | 0.6 |
| rain   | 0.1 |
| fog    | 0.3 |
| meteor | 0.0 |

$$\begin{aligned} P(\text{hot}) &= P(T = \text{hot}), \\ P(\text{cold}) &= P(T = \text{cold}), \\ P(\text{rain}) &= P(W = \text{rain}), \end{aligned}$$

- 变量的某一个取值的可能对应一个概率值。

$$P(W = \text{rain}) = 0.1$$

- 概率（小写值）是一个数，且必须满足。

$$\forall x \ P(X = x) \geq 0 \quad \sum_x P(X = x) = 1$$

## 贝叶斯网络：概率基础

### 联合概率分布

- 一组随机变量赋值组合在联合概率分布中对应一个概率值：

$$X_1, X_2, \dots, X_n$$

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

$$P(x_1, x_2, \dots, x_n)$$

- 概率分布服从：

$$P(x_1, x_2, \dots, x_n) \geq 0$$

$$\sum_{(x_1, x_2, \dots, x_n)} P(x_1, x_2, \dots, x_n) = 1$$

- 假设有n个随机变量，变量有d个取值，则概率分布包含多少个概率值？

$$P(T, W)$$

| T    | W    | P   |
|------|------|-----|
| hot  | sun  | 0.4 |
| hot  | rain | 0.1 |
| cold | sun  | 0.2 |
| cold | rain | 0.3 |

## 贝叶斯网络：概率基础

### 事件

- 事件是结果（一组概率赋值）的集合，记为 E。

$$P(E) = \sum_{(x_1, \dots, x_n) \in E} P(x_1, \dots, x_n)$$

- 根据联合概率分布，我们可以计算出任何事件的概率  $P(T, W)$

- 气温高且晴天的概率？
- 气温高的概率？
- 气温高或晴天的概率？

| T    | W    | P   |
|------|------|-----|
| hot  | sun  | 0.4 |
| hot  | rain | 0.1 |
| cold | sun  | 0.2 |
| cold | rain | 0.3 |

## 贝叶斯网络：概率基础

### 边缘概率分布

- 边缘概率分布是联合概率分布表中消去一些变量后的子表。

$$P(X_1 = x_1) = \sum_{x_2} P(X_1 = x_1, X_2 = x_2)$$

- 边缘化（加和操作）：将目标变量取值相同的行通过加和的形式合并，完成变量删除。

| $P(T, W)$ |      |     | $P(T)$ |     |
|-----------|------|-----|--------|-----|
| T         | W    | P   | T      | P   |
| hot       | sun  | 0.4 | hot    | 0.5 |
| hot       | rain | 0.1 | cold   | 0.5 |
| cold      | sun  | 0.2 |        |     |
| cold      | rain | 0.3 |        |     |

$$P(t) = \sum_s P(t, s)$$

| $P(W)$ |     |
|--------|-----|
| W      | P   |
| sun    | 0.6 |
| rain   | 0.4 |

$$P(s) = \sum_t P(t, s)$$

## 贝叶斯网络：概率基础

### 条件概率分布

- 条件概率分布是给定条件变量的取值之后目标变量的概率分布。

$$P(x|y) = \frac{P(x, y)}{P(y)}$$

| 联合概率分布    |      |     | 边缘概率分布 |     | 条件概率分布                |     |
|-----------|------|-----|--------|-----|-----------------------|-----|
| $P(T, W)$ |      |     | $P(T)$ |     | $P(W T = \text{hot})$ |     |
| T         | W    | P   | T      | P   | W                     | P   |
| hot       | sun  | 0.4 | hot    | 0.5 | sun                   | 0.8 |
| hot       | rain | 0.1 | cold   | 0.5 | rain                  | 0.2 |
| cold      | sun  | 0.2 |        |     |                       |     |
| cold      | rain | 0.3 |        |     |                       |     |

$$P(W|T) = \frac{P(W, T)}{P(T)}$$

| $P(W T = \text{cold})$ |     |
|------------------------|-----|
| W                      | P   |
| sun                    | 0.4 |
| rain                   | 0.6 |

## 贝叶斯网络：概率基础

### 乘法法则

$$P(x|y) = \frac{P(x,y)}{P(y)} \iff P(y)P(x|y) = P(x,y)$$

例子：

| $P(W)$ |     | $P(T W)$ |      |      | $P(W,T)$ |      |   |
|--------|-----|----------|------|------|----------|------|---|
| W      | P   | T        | W    | P    | T        | W    | P |
| sun    | 0.6 | hot      | sun  | 2/3  | hot      | sun  |   |
| rain   | 0.4 | cold     | sun  | 1/3  | cold     | sun  |   |
|        |     | hot      | rain | 0.25 | hot      | rain |   |
|        |     | cold     | rain | 0.75 | cold     | rain |   |

## 贝叶斯网络

### 链式法则

更一般的情况，可以将任何联合分布写为条件分布的乘积。

$$P(x_1, x_2, x_3) = P(x_1)P(x_2|x_1)P(x_3|x_1, x_2)$$

$$P(x_1, x_2, \dots, x_n) = \prod_i P(x_i|x_1 \dots x_{i-1})$$

## 贝叶斯网络：贝叶斯公式

### 乘法法则

基于乘法法则，有两种分解联合概率的方法：

$$P(x, y) = P(x|y)P(y) = P(y|x)P(x)$$

两边除以先验概率，得到贝叶斯公式：

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$



贝叶斯公式的作用

- 从一个条件概率计算逆向的条件概率。
- 通常一个条件概率很难获得，而另一个条件概率很容易得到。
- 是许多人工智能系统的基础算法（例如ASR，MT）。

## 贝叶斯网络：贝叶斯公式

### 利用贝叶斯公式进行推理

由症状判断疾病

$$P(\text{cause}|\text{effect}) = \frac{P(\text{effect}|\text{cause})P(\text{cause})}{P(\text{effect})}$$

M: Meningitis (脑膜炎)

S: stiff neck (落枕)

$$P(+m) = 0.0001$$

$$P(+s|m) = 0.8$$

$$P(+s|-m) = 0.01$$

$$P(+m|+s) = ?$$

$$P(+m|+s) = \frac{P(+s|m)P(+m)}{P(+s)} = \frac{P(+s|m)P(+m)}{P(+s|m)P(+m) + P(+s|-m)P(-m)} = \frac{0.8 \times 0.0001}{0.8 \times 0.0001 + 0.01 \times 0.9999}$$

脑膜炎的后发几率仍然很小：0.007944。

但是，在获得落枕这个症状之后，患病概率提升了80倍，

## 贝叶斯网络：贝叶斯公式

### 独立性

在以下情况，两个变量在联合分布中是独立的：

$$P(X, Y) = P(X)P(Y) \quad X \perp\!\!\!\perp Y$$

$$\forall x, y \quad P(x, y) = P(x)P(y)$$

联合概率可以分解为两个简单的先验概率的乘积。

使用独立性作为建模假设，可以简化问题。

- 我们可以对这4个变量 {Weather, Traffic, Cavity} 做什么假设？
- $W \perp C, C \perp T$

## 贝叶斯网络

### 条件独立性

条件独立性是建模不确定环境最基本也是最有力的方式。

给定Z时，X条件独立于Y：

$$X \perp\!\!\!\perp Y | Z$$

当且仅当：

$$\forall x, y, z : P(x, y|z) = P(x|z)P(y|z)$$

或者等价地，当且仅当：

$$\forall x, y, z : P(x|z, y) = P(x|z)$$

## 贝叶斯网络：概率推理

### 概率推理

- 概率推理：从已知概率分布计算目标概率分布。
- 通常基于联合概率求解条件概率。
  - $P(\text{on time} \mid \text{no reported accidents}) = 0.90$
  - 表示，给定一个证据，一个智能体对于某事件发生的置信度有多少。
- 随着新证据出现，概率发生变化：
  - $P(\text{on time} \mid \text{no accidents, 5 a.m.}) = 0.95$
  - $P(\text{on time} \mid \text{no accidents, 5 a.m., raining}) = 0.80$
  - 观察到新的证据后，置信度随之更新。

## 贝叶斯网络

### 枚举推理

- 问题定义：
  - 证据变量：  $E_1 \dots E_k = e_1 \dots e_k$
  - 查询变量：  $Q$
  - 隐藏变量：  $H_1 \dots H_r$
  - 目标概率：  $P(Q|e_1 \dots e_k)$
- 第一步：在联合概率分布表中选择和证据变量相一致的条目。
- 第二步：行概率相加消除隐藏变量，得到查询和证据变量的联合分布。
- 第三步：归一化。

$$P(Q, e_1 \dots e_k) = \sum_{h_1 \dots h_r} \underbrace{P(Q, h_1 \dots h_r, e_1 \dots e_k)}_{X_1, X_2, \dots, X_n} \quad Z = \sum_q P(Q, e_1 \dots e_k)$$

$$P(Q|e_1 \dots e_k) = \frac{1}{Z} P(Q, e_1 \dots e_k)$$

## 贝叶斯网络


### 贝叶斯网络

- 贝叶斯网络：一种用局部分布(条件概率分布)来描述联合分布的模型。
  - 也称作概率图模型。
  - 贝叶斯网络描述变量之间的局部交互关系。
  - 全局的变量关系可以通过整合局部关系得到。

## 贝叶斯网络

### 贝叶斯网络


- 节点：变量(有值域)，已赋值/未赋值。
- 边：节点之间的直接联系。
- 贝叶斯网络
  - 一个节点集合，每一个节点对应一个变量。
  - 一个有向无环图。
  - 一组条件概率，每一个对应一个变量  $X$ 。
  - $X$  的条件概率是给定该节点所有父亲节点作为条件。
  - 每一个入项对应一组父亲节点的赋值组合。



贝叶斯网络= 拓朴(图) + 局部条件概率

## 贝叶斯网络

### 贝叶斯网络



## 贝叶斯网络

### 构造贝叶斯网络


- 输入：一组变量节点
- 输出：一个有向无环图
- 由小到大给节点编号 (1 到 N)。
- 按照编号从小到大将节点加入图中。
- 当新增节点与图中节点存在交互关系，从图中节点连线指向新增节点。
- 使用什么交互关系？
  - 可以使用因果关系。
- 如何保证构建的图中不存在环？
  - 有向边是从序号小的节点指向序号大的节点。

## 贝叶斯网络

### 举例：警报网络


- 变量（自上而下，将变量添加到贝叶斯网络图中）

- B: 遭贼 (Burglary)
- E: 地震 (Earthquake)
- A: 警报响 (Alarm)
- M: 玛丽打电话 (Mary calls)
- J: 约翰打电话 (John calls)



## 贝叶斯网络

### 举例：警报网络




## 贝叶斯网络

### 贝叶斯网络中的联合概率

- 贝叶斯网络隐式地表示联合分布
- 以局部条件概率分布的乘积表示

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- 例子:



$$P(+cavity, +catch, -toothache) = P(+cavity) * P(+catch | +cavity) * P(-toothache | +cavity)$$

## 贝叶斯网络

### 条件独立性

- X 和 Y 是独立的:

$$\forall x, y \quad P(x, y) = P(x)P(y) \quad \text{---} \rightarrow \quad X \perp\!\!\!\perp Y$$

- 给定 Z, X 和 Y 是条件独立的:

$$\forall x, y, z \quad P(x, y | z) = P(x | z)P(y | z) \quad \text{---} \rightarrow \quad X \perp\!\!\!\perp Y | Z$$

- (条件) 独立性是概率分布的一个性质
  - 如果独立性对于变量的任何赋值都成立, 那么, 就可以把变量大写。

## 贝叶斯网络

### 贝叶斯网络中的条件独立性

- 如何保证贝叶斯网络的联合概率形式?

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

- 链式法则 (对所有分布成立):

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | x_1 \dots x_{i-1})$$

- 假设 条件独立性:

$$x_i \perp\!\!\!\perp \{x_1, \dots, x_{i-1} / \text{parents}(x_i)\} | \text{parents}(x_i)$$

→ 结果:

$$P(x_i | x_1, \dots, x_{i-1}) = P(x_i | \text{parents}(X_i))$$

$$P(x_1, x_2, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$


## 贝叶斯网络

### 贝叶斯网络规模

- N 个布尔值域变量的联合概率分布。
- 概率分布表有多大?
  - $2^n$
- 如果每个变量至多 k 个父节点, 对应的贝叶斯网络有多大?
  - $n * 2^{k+1}$
- 全联合概率分布表和贝叶斯网络都可以用来计算联合概率。
- 贝叶斯网络: 节省存储空间, 加速计算。

## 贝叶斯网络

### 举例：抛硬币




$$P(h, h, t, h) = P(x_1 = h) * P(x_2 = h) * P(x_3 = t) * P(x_4 = h)$$

只有变量间完全独立的分布对应的贝叶斯网络才是没有边的。


## 贝叶斯网络

### 课堂作业



## 贝叶斯网络

### 贝叶斯网络中的因果关系



R: 下雨

T: 交通堵塞

贝叶斯网络中的边不需反映因果关系。

## 贝叶斯网络


### 贝叶斯网络中的因果关系

- 使用因果关系构建贝叶斯网络时：
  - 通常更简单（节点的父节点更少）。
  - 通常更容易构建。
  - 通常更容易从专家处获得支撑。
- 贝叶斯网络并不一定需要因果关系：
  - 在建模的问题中，因果关系不一定存在（尤其当有变量缺失时），比如，以变量堵车和下雨为例。
  - 箭头只反映相关性，不反映因果。
  - 箭头到底代表什么？
- 拓扑图也许表示因果关系，但真正表达的是条件独立性
 
$$P(x_i | x_1, \dots, x_{i-1}) = P(x_i | \text{parents}(x_i))$$

$$x_i \perp\!\!\!\perp x_1, \dots, x_{i-1} | \text{parents}(x_i)$$

## 贝叶斯网络

### 举例



- 条件独立性假设可以从链式法则的简化表示直接推导而来：

$$P(X, Y, Z, W) = P(X)P(Y|X)P(Z|X, Y)P(W|X, Y, Z) = P(X)P(Y|X)P(Z|Y)P(W|Z)$$

- 蕴含的条件独立性：

$$X \perp\!\!\!\perp Z | Y \quad X \perp\!\!\!\perp W, Y \perp\!\!\!\perp W | Z$$

- 其他隐含的条件独立性假设？

$$X \perp\!\!\!\perp W ? \quad X \perp\!\!\!\perp W | Y ?$$

## 目录：

- 逻辑Agent
- 决策
- 学习


## 学习

- Agent为什么需要学习?
- 理论上, 可以仅仅通过手工编程实现理性Agent吗?
- $\Rightarrow$ 所有可以通过编程完成的任务, 其一致的特点是世界是清楚的。
- 但真实世界是不清楚的:
- 环境无法全部预测 $\Rightarrow$ 如何让围棋AI打扑克?
- 环境的变化无法全部预测 $\Rightarrow$ 股市
- 程序员可能不知道怎么写 $\Rightarrow$ 如何写代码识别人脸?

## 学习

- 学习是一种什么行为?
- 雨水落下, 长时间沿着一个路线在大地流过 $\Rightarrow$ 河流。
- 河流是大地对水经常流过的一种记忆, 那如果我们想手动创造一条河应该怎么做? 挖人工河吗?
- 最准确的方法是: 创造一片大地, 再人工降雨, 时间长了出来的就是河。
- 我们的视觉、听觉、味觉、触觉信号长时间流过神经细胞, 构造了大脑中神经元之间的复杂联系, 这种复杂联系就是我们一般认知上的自我意识和记忆。这种复杂的联系是无法由DNA记录完毕的 $\Rightarrow$ 记忆无法遗传。
- 学习是使用一种可操作的载体对世界环境的一种记忆。
- 我们称这种载体为“模型”, 这个记忆过程为“模型训练”。

## 学习



## 学习

- 学习条件反射
  - $\Rightarrow$ 当前状态下, 条件到动作的直接映射 (动物)
- 学习理解环境
  - $\Rightarrow$ 由感知信息推演世界特征 (理解)
- 学习行为结果
  - $\Rightarrow$ 由Agent的动作来推测行为结果 (行为判断)
- 学习效用函数
  - $\Rightarrow$ 当前状态下的效用信息
  - $\Rightarrow$ 动作产生的价值
  - $\Rightarrow$ 最大化Agent效用的目标量化方式

## 学习

- 正态分布模型
  - 假设环境满足正态分布, 再训练模型参数
  - 新数据来时, 可以用于预测, 如一个50人的班级超过一半是满分, 那么要么是考试太简单要么是。。。
- 贝叶斯网络
  - 先验概率来自经验或统计数据, 条件概率来自训练样本
  - 新数据来时, 可以用于预测, 如家里接到邻居电话说家里铃想了 $\Rightarrow$ 有窃贼
- 本质上, 模型都可以认为是一个  $f$


## 学习

- 最简单的形式: 从例子中学习函数
  - “白板说”, theory of tabula rasa
- 假设  $f$  是真实世界的反应, 但  $f$  未知
- 目标是给定一组  $x$ , 模型能够找到  $f(x)$  的值
- 设一个函数  $h$ , 使得在利用训练集训练后,  $h = f$
- 这是一个简化的学习模型:
  - 没有先验知识,  $h$  没有方向
  - 假设了一个确定性的、可观察的“环境”
  - 假设了存在训练集, 且训练集和  $h$  是匹配的
  - 假设了agent想要学习  $f$  - 为什么?

|     |     |     |
|-----|-----|-----|
| $o$ | $o$ | $x$ |
| $x$ |     | $x$ |

## 学习

- 构造/调整  $h$ , 使其在训练集上与  $f$  一致: 定义一致为在所有例子上  $h$  都与  $f$  一致
- 例如, 曲线拟合:



- 最大化一致性和简单性的结合: 奥卡姆剃刀原则

## 学习

- 是否要在饭店中等待餐桌?
- 属性:
- *Alternate*: 附近是否有一个候选饭店。
- *Bar*: 饭店中是否有等待区 (小酒吧)
- *Fri/Sat*: 周五或周六
- *Hungry*: 是否饿了
- *Patrons*: 饭店中客人数量
- *Price*: 饭店价格区间
- *Raining*: 是否下雨
- *Reservation*: 是否预订
- *Type*: 饭店类型
- *WaitEstimate*: 主人对等待的估计

## 学习


- 上述属性有布尔值、离散值、连续值等, 那么选择等待/不等待一个空桌的情况:

| Example  | Alt | Bar | Fri | Hun | Pat  | Price  | Rain | Res | Type    | Est   |
|----------|-----|-----|-----|-----|------|--------|------|-----|---------|-------|
| $X_1$    | T   | F   | F   | T   | Some | \$\$\$ | F    | T   | French  | 0-10  |
| $X_2$    | T   | F   | F   | T   | Full | \$     | F    | F   | Thai    | 30-60 |
| $X_3$    | F   | T   | F   | F   | Some | \$     | F    | F   | Burger  | 0-10  |
| $X_4$    | T   | F   | T   | T   | Full | \$     | F    | F   | Thai    | 10-30 |
| $X_5$    | T   | F   | T   | F   | Full | \$\$\$ | F    | T   | French  | >60   |
| $X_6$    | F   | T   | F   | T   | Some | \$\$   | T    | T   | Italian | 0-10  |
| $X_7$    | F   | T   | F   | F   | None | \$     | T    | F   | Burger  | 0-10  |
| $X_8$    | F   | F   | T   | T   | Some | \$\$   | T    | T   | Thai    | 0-10  |
| $X_9$    | F   | T   | T   | F   | Full | \$     | T    | F   | Burger  | >60   |
| $X_{10}$ | T   | T   | T   | T   | Full | \$\$\$ | F    | T   | Italian | 10-30 |
| $X_{11}$ | F   | F   | F   | F   | None | \$     | F    | F   | Thai    | 0-10  |
| $X_{12}$ | T   | T   | T   | T   | Full | \$     | F    | F   | Burger  | 30-60 |

- 对这些例子分类为正(T)或负(F)


## 学习

- 假设的一种可能表示
- 下面是用来决定是否等待的“真”树:



## 学习

- 决策树可以表示输入属性的任何函数。例如, 对于布尔函数, 真值表的一行  $\Rightarrow$  到达叶子的一条路径:



- 一般来说, 对于任何训练集都有一个一致的决策树
- 对于每个训练集来说, 每个样本都对应了一个到叶节点的路径。(注意, 如果  $x$  训练下的  $f$  本身是无法确定的, 那就不适用该模型)
- 另外, 决策树泛化性较弱, 且树结构越紧凑越好

## 学习

- 多少不同的决策树有  $n$  个布尔属性?  
= 布尔函数个数  
= 不同的真值表的数目  $2^n$  行  
=  $2^{2^n}$
- $\Rightarrow$  如果有 6 个布尔属性, 就有 18446744073709551616 棵树!

- 有多少纯粹的联合假设(例如,  $Hungry \wedge \neg Rain$ )?
- 每个属性可以是 in (positive)、in (negative) 或 out  
 $\Rightarrow 3^n$  不同的合置假设
- 使用假设空间 (hypothesis space) 能增强表达性:
  - 更有可能准确表示目标函数
  - 同时增加了与训练集一致的假设数
    - 可能会让预测变糟

## 学习

- 目标: 找到与训练实例一致的小树
- 思想: (递归地)选择“最重要的”属性作为(子)树的根

```
function DTL(examples, attributes, default) returns a decision tree
 if examples is empty
 then return default
 else if all examples have the same classification
 then return the classification
 else if attributes is empty
 then return Mode(examples)
 else
 best ← Choose-Attribute(attributes, examples)
 tree ← a new decision tree with root test best
 for each value v_i of best do
 examplesi ← {elements of examples with best= v_i }
 subtree ← DTL(examplesi, attributes - best, Mode(examples))
 add a branch to tree with label v_i and subtree subtree
 return tree
```

## 学习

- 思路: 一个好的属性可以把例子分成“全部肯定”或“全部否定”(理想情况下)的子集。



- *Patrons?* 是否是更好的选择: 需要给出关于分类的信息

## 学习


- 信息用于回答问题
- 如果我对最初的答案越不了解, 答案中包含的信息就越多
- 抽象为: 1bit=在先验概率(0.5, 0.5)时布尔问题的答案
- 先验概率为( $P_1, \dots, P_n$ )时, 信息就是:
 
$$H((P_1, \dots, P_n)) = - \sum_{i=1}^n P \log_2 P$$
- 这也称为先验熵

## 学习

- 假设在决策树树根有  $p$  个正例和  $n$  个负例
  - $\Rightarrow H((p/(p+n), n/(p+n)))$  分类一个新实例需要的bits
  - 如, 当有12个餐馆时,  $p=n=6$ , 所以我们需要1bit
- 一个属性将实例集合  $E$  分割成子集  $E_i$ , 我们希望每个子集完成分类需要的信息数量越少越好
- 设  $E_i$  有  $p_i$  个正样本,  $n_i$  个负样本
  - $\Rightarrow H((p_i/(p_i+n_i), n_i/(p_i+n_i)))$  分类一个新实例需要的bits
  - $\Rightarrow$  所有分支上的每个实例的期望bits是:
 
$$\sum_i \frac{p_i + n_i}{p + n} H((p_i/(p_i+n_i), n_i/(p_i+n_i)))$$
- *Patrons?* 0.459bits
- *Type?* 1bit
- $\Rightarrow$  选择最小化所需剩余信息的属性

## 学习


- 从12个例子中学习决策树:



- 比“真正的”树简单得多——复杂的假设不能被少量的数据所证实


## 学习

- 我们怎么知道  $h = f$ ?——休谟的问题归纳法
- 使用计算/统计学习理论的定理
- 在一组新的实例上测试函数  $h$
- (在实例空间上使用与训练集相同的分布)
- 学习曲线: 将测试集作为训练集分割出的百分比的函数



## 学习

- 学习曲线取决于
- 可实现(可以表达目标功能)vs. 不可实现
- 不可实现性可能是由于缺少属性
- 或受限假设类(如阈值是线性函数)
- 表达多余(存在大量不相关的属性)



## 学习

- 对于监督学习 (supervised learning), 目标是找到一个最简单的假设函数  $h$  使之和训练集的数据足够契合
- 学习性能 = 在测试集的预测精度
- 衡量学习算法好坏, 既要考虑准确性, 也要考察泛化性
- 决策树基于信息熵进行学习, 类似的, 在有限的数据样本下进行学习的算法都称为统计学习算法。